


BERT. Pre-training of Deep Bidirectional Transformers for Language Understanding

BERT

BERT (Bidirectional Encoder Representations from Transformers) - [Encoder-only Transformer](#).



Особенности

- Использует двунаправленное [внимание](#)
- Размер контекста ограничен

Эмбединги токенов

Input	[CLS]	my	dog	is	cute	[SEP]	he	likes	play	##ing	[SEP]
Token Embeddings	$E_{[CLS]}$	E_{my}	E_{dog}	E_{is}	E_{cute}	$E_{[SEP]}$	E_{he}	E_{likes}	E_{play}	$E_{\#ing}$	$E_{[SEP]}$
	+	+	+	+	+	+	+	+	+	+	+
Segment Embeddings	E_A	E_A	E_A	E_A	E_A	E_A	E_B	E_B	E_B	E_B	E_B
	+	+	+	+	+	+	+	+	+	+	+
Position Embeddings	E_0	E_1	E_2	E_3	E_4	E_5	E_6	E_7	E_8	E_9	E_{10}

- Эмбединги каждого слова состоят из 3 частей
 1. WordPiece
 2. Сегментные эмбединги

- Всего 2 эмбединга
- Используются при наличии $[SEP]$
 - Иначе все токены из сегмента A


3. Позиционные эмбединги

- Похоже на [Positional Encoding](#)
- Для каждой позиции свой эмбединг
- Вывод:
 - Размер контекста ограничен

Pre-train

- Masked Language Model (MLM)
 - Маскируем 15% всех токенов:
 - 10% оставляем как было
 - 10% заменяем случайным токеном
 - 80% заменяя специальный токеном $[MASK]$
 - Обучаем маскированный токен на многоклассовую классификацию
 - Предсказание нужного токена
 - [CrossEntropyLoss](#)
- Next Sentence Prediction (NSP)
 - Спереди последовательности втыкаем токен $[CLS]$
 - Подаем две последовательности:
 - A - First Sentence
 - B - Second Sentence
 - Склеиваем их через специальный токен $[SEP]$
 - Распределение
 - 50% Правильных
 - 50% Неправильных
 - Обучаем эмбединг $[CLS]$ на бинарную классификацию

- [BinaryCrossEntropyLoss](#)



Датасет

- BooksCorpus (800M words)
- English Wikipedia (2,500M words)
 - Использовались только отрывки с текстом
 - Избегались списки, таблицы и заголовки